

Estado del arte

Accountability y *explainability* en sistemas ciberfísicos autónomos

Versión 1.1

Información del documento

Proyecto	EXPLICIT
Tipo de documento	Estado del arte
Fecha	28/10/2026
Autoría	Grupo de Robótica · Universidad de León
Palabras clave	*Accountability* · *Explainability* · Trazabilidad · Caja negra · Sistemas autónomos

Registro de modificaciones

Versión	Fecha	Responsable	Descripción del cambio
0.1	22/10/2026	Equipo EXPLICIT	Creación de la plantilla
1.0	26/10/2026	Equipo EXPLICIT	Reescritura integral y actualización bibliográfica

Tabla de contenidos

Estructura del documento

1 Introducción y delimitación 4
1.1 Contextualización del tema 4
1.2 Alcance y delimitación 5
1.3 Objetivos 5
2 Marco de búsqueda y criterios seleccionados 6
2.1 Estrategia de selección 6
2.2 Fuentes principales 6
3 Núcleo temático y categorización de la literatura 7
3.1 Evolución y corrientes teóricas 7
3.2 Ejes o líneas de investigación 9
3.2.1 *Accountability* y asignación de responsabilidad 9
3.2.2 Registro de eventos y registradores de caja negra 9
3.2.3 Integridad resistente a manipulaciones y cadena de bloques 10
3.2.4 Generación de explicaciones estructuradas 11
3.2.5 Grandes modelos de lenguaje, recuperación aumentada y explicaciones multimodales 12
3.2.6 Regulación, estándares y ciberseguridad 13
3.3 Consensos y hallazgos principales 14
4 Justificación de la propuesta EXPLICIT 15
Referencias 17

1 Introducción y delimitación

1.1 Contextualización del tema

Los sistemas autónomos combinan percepción, cómputo, comunicación y actuación sobre el mundo físico. En un robot móvil, por ejemplo, una misma conducta puede depender de sensores parcialmente observables, modelos de localización, un planificador, políticas aprendidas, reglas de seguridad, y la intervención de operadores o servicios externos. Esta distribución del control dificulta responder de forma rigurosa a tres preguntas distintas: qué ocurrió, por qué ocurrió y quién o qué debía responder por ello. La literatura reciente converge en que ninguna de esas preguntas puede resolverse únicamente inspeccionando el resultado final del sistema [1], [2].

En este estado del arte se usa *accountability* para designar la capacidad sociotécnica de reconstruir una actuación, contrastarla con reglas y responsabilidades previamente definidas y aportar evidencia suficiente para que un actor competente pueda exigir una rendición de cuentas. No se equipara *accountability* con responsabilidad jurídica ni con culpabilidad. La primera es una propiedad que debe diseñarse mediante procesos, funciones y evidencia; las segundas dependen de un marco normativo y de una decisión institucional [2].

Explainability se refiere a la capacidad de ofrecer a un destinatario una razón comprensible y pertinente sobre una conducta, decisión, fallo o límite del sistema. Una explicación fluida sin evidencia puede ser una racionalización plausible; un registro íntegro puede ser ininteligible para una persona no técnica; y una cadena de eventos técnicamente completa no determina por sí misma qué actor era responsable. La relación operativa entre estas propiedades puede sintetizarse como una cadena: captura del evento, preservación de su procedencia, reconstrucción temporal y causal, generación de una explicación y evaluación por la parte interesada adecuada [3]–[5].

El problema ha adquirido especial relevancia por tres razones. Primero, los sistemas autónomos ya actúan en espacios compartidos con personas y sus fallos pueden producir consecuencias físicas. Segundo, los modelos de aprendizaje han aumentado la capacidad funcional, pero también la opacidad, la dependencia de datos externos y el riesgo de alucinaciones. Tercero, el marco europeo ha convertido registro, supervisión humana, documentación técnica, robustez y ciberseguridad en requisitos de diseño y de ciclo de vida para distintos tipos de sistemas de IA y maquinaria [32]–[36]. La cuestión ya no es si conviene registrar y explicar, sino qué debe registrarse, con qué garantías, para quién debe explicarse y cómo demostrar que la explicación está fundamentada en el comportamiento real.

La investigación se organiza en dos tradiciones que durante años evolucionaron con escasa integración. La primera estudia *accountability* mediante el registro de eventos, los registradores de caja negra, la procedencia, la criptografía y la cadena de bloques. La segunda estudia los robots autónomos explicables mediante modelos causales, planificación, árboles de comportamiento, ontologías, verbalización y, más recientemente, grandes modelos de lenguaje y modelos visión-lenguaje. Los trabajos desarrollados en el entorno TESCAC y EXPLICIT conectan ambas tradiciones: una capa registra evidencia con garantías de integridad y confidencialidad; otra recupera esa evidencia y genera explicaciones en lenguaje natural [6]–[9], [20]–[23]. Esta convergencia es prometedora, pero todavía no constituye una solución cerrada. Persisten problemas de selección de datos, latencia, privacidad, causalidad, verificación y evaluación con usuarios.

1.2 Alcance y delimitación

La revisión adopta un alcance conceptual centrado en sistemas autónomos con capacidad de actuar físicamente y, en particular, en robots que emplean ROS o ROS 2. Incluye contribuciones de IA, robótica, interacción persona-robot, ciberseguridad, sistemas distribuidos y gobernanza cuando ayudan a construir o evaluar una cadena verificable entre comportamiento, evidencia y explicación. Se consideran tanto mecanismos posteriores al evento orientados a la investigación forense como explicaciones durante la operación, siempre que mantengan una conexión explícita con el estado o las decisiones del sistema.

El intervalo principal abarca de 2017 al 23 de octubre de 2026. El inicio coincide con la formulación pública de la caja negra ética y con trabajos que conectan transparencia, *explainability* y *accountability* en robótica [1], [3]. Se incorporan antecedentes anteriores cuando establecen un método que sigue estructurando el campo, como la verbalización de experiencias de navegación [43]. El corte final permite integrar publicaciones de 2026 disponibles en el corpus y cambios regulatorios ya vigentes a esa fecha.

Se excluyen tres grupos. Primero, métodos genéricos de IA explicable (XAI) aplicados a clasificadores estáticos cuando no consideran la presencia física, la interacción temporal ni las consecuencias materiales. Segundo, registros puramente operativos que no abordan procedencia, integridad, reconstrucción o uso explicativo. Tercero, propuestas sobre ética o confianza que no traducen sus principios en requisitos, mecanismos o criterios de evaluación. Esta delimitación no niega su valor; evita que el objeto de estudio se diluya en toda la literatura de IA responsable.

La unidad de análisis no es el algoritmo aislado, sino la cadena de *accountability* y *explainability* de un sistema autónomo. Esta cadena comprende al menos: fuentes de evidencia; selección y representación de eventos; protección criptográfica y control de acceso; almacenamiento y recuperación; modelo de comportamiento o contexto; generación de explicaciones; adaptación a la parte interesada; y evaluación técnica y humana.

1.3 Objetivos

El objetivo general es construir una síntesis crítica y actualizada que permita situar la contribución de EXPLICIT frente a la literatura existente. No se busca elaborar un inventario de autores, sino identificar las decisiones de diseño que explican por qué unas propuestas producen evidencia verificable, otras explicaciones comprensibles y muy pocas consiguen ambas cosas de manera conjunta.

Los objetivos específicos son los siguientes:

- precisar las relaciones y diferencias entre *accountability*, *explainability*, trazabilidad, transparencia y capacidad de auditoría en sistemas ciberfísicos autónomos;
- reconstruir la evolución desde la caja negra conceptual y los métodos explicativos estructurados hasta las arquitecturas con cadena de bloques, generación aumentada por recuperación (RAG), grandes modelos de lenguaje (LLM) y modelos visión-lenguaje (VLM);
- agrupar la literatura por problemas técnicos y humanos comparables, en lugar de por orden cronológico o por base de datos;
- analizar las metodologías empíricas predominantes y el tipo de evidencia que permite sostener cada una;

- identificar consensos, controversias y vacíos que condicionan el paso desde la prueba de concepto a sistemas desplegables;

2 Marco de búsqueda y criterios seleccionados

2.1 Estrategia de selección

La revisión es un estado del arte narrativo con búsqueda estructurada, no una revisión sistemática. La diferencia es deliberada: se pretende conectar tradiciones que emplean vocabularios y métodos distintos, no estimar un efecto agregado ni reproducir una única ecuación de búsqueda.

2.2 Fuentes principales

El núcleo bibliográfico está formado por publicaciones en revistas científicas de alto impacto como *IEEE Access*, *IEEE Robotics and Automation Letters*, *IEEE Transactions on Industrial Informatics*, *Logic Journal of the IGPL*, *ACM Transactions on Human-Robot Interaction*, *Advanced Robotics* y *Artificial Intelligence*, así como por actas de congresos científicos como HRI, IJCAI, HAIS y WAF. Estas fuentes cubren, respectivamente, revisiones sistemáticas, formalización de *accountability*, arquitecturas de registro, almacenamiento resistente a manipulaciones, generación de explicaciones, interacción con usuarios y evaluación de prototipos.

3 Núcleo temático y categorización de la literatura

3.1 Evolución y corrientes teóricas

La investigación sobre *accountability* en robótica —entendida como la capacidad de rendir cuentas sobre el comportamiento de un sistema— ha avanzado en torno a dos necesidades complementarias: disponer de evidencias fiables sobre lo ocurrido y ofrecer explicaciones que permitan comprenderlo. A partir de estas necesidades pueden distinguirse cuatro corrientes que, aunque surgieron desde perspectivas diferentes, han ido convergiendo.

La primera corriente aborda la *accountability* como una propiedad que debe incorporarse al diseño del sistema. Wachter, Mittelstadt y Floridi defendieron que la transparencia, la explicabilidad y la *accountability* debían tratarse conjuntamente, sin asumir que mostrar el funcionamiento técnico de un robot basta para atribuir responsabilidades [1]. Kacianka y Pretschner profundizaron en esta idea al definir la *accountability* como la capacidad de descubrir las causas de un resultado y comprender quién o qué es responsable. Su trabajo mostró, además, que adoptar una definición u otra conduce a arquitecturas diferentes [2]. Desde esta perspectiva, la «caja negra ética» trasladó a la robótica la lógica del registrador de vuelo: conservar datos de sensores, actuadores y estados, con marcas temporales, para facilitar la investigación de accidentes y cuasiaccidentes [3]. Un posterior borrador de estándar abierto concretó las categorías de datos y propuso una arquitectura modular para robots sociales [4].

Entre 2017 y 2021, esta corriente pasó de justificar la necesidad de conservar evidencias a desarrollar mecanismos que garantizaran su fiabilidad. White y colaboradores combinaron firmas, HMAC, cadenas de resúmenes criptográficos y puntos de control en una cadena de bloques para crear registros resistentes a la manipulación en ROS 2 [5]. Así, la *accountability* dejó de limitarse al almacenamiento de mensajes e incorporó requisitos de autenticidad, integridad, no repudio e independencia respecto del sistema auditado. En paralelo, IEEE 7001 estableció niveles medibles de transparencia para distintos grupos, desde usuarios hasta investigadores de accidentes [10]. Con ello se hizo explícita una cuestión central: la información necesaria para comprender un robot depende de quién la recibe y con qué propósito.

Esta atención a las necesidades del destinatario conecta con la segunda corriente, procedente de la inteligencia artificial explicable (XAI) y de la interacción persona-robot. Miller mostró que las explicaciones humanas son selectivas, contrastivas y sociales: suelen responder a preguntas concretas y explicar por qué ocurrió algo en lugar de otra alternativa. Por ello, una exposición exhaustiva de variables puede resultar menos útil que una respuesta pertinente en un contexto determinado [11]. Gunning y Aha consolidaron la agenda de XAI, mientras que las revisiones sobre agentes explicables y agentes corpóreos identificaron una terminología fragmentada y métodos de evaluación heterogéneos [12]–[14]. En robótica, Sakai y Nagai concretaron cuatro capacidades necesarias: disponer de un espacio de decisión interpretable, estimar qué entiende el usuario, seleccionar la información que necesita y comunicarla mediante un canal eficaz [15]. El objetivo pasa así de mostrar el funcionamiento del modelo a facilitar la comprensión en la relación entre el robot y la persona.

Sin embargo, una explicación comprensible también debe reflejar las razones que guiaron la decisión. La tercera corriente busca esta fidelidad mediante representaciones estructuradas. La reconciliación de

modelos, por ejemplo, explica un plan identificando las diferencias entre el modelo del robot y el del usuario [17]. Los árboles de comportamiento permiten recorrer objetivos, subobjetivos, pasos y acciones para reconstruir qué hizo el robot, cómo lo hizo y dónde falló [18]. Las arquitecturas normativas incorporan, además, propósitos y reglas sociales, y advierten que una justificación elaborada después de actuar no equivale necesariamente a una explicación causal [19]. Estos enfoques comparten una ventaja: generan explicaciones a partir de estructuras que intervienen en la decisión. Su principal limitación es el esfuerzo de modelado y la dificultad para abarcar la percepción no estructurada, el aprendizaje continuo y la interacción multimodal.

Desde 2023, una cuarta corriente explora el uso de modelos generativos para convertir las trazas técnicas en explicaciones en lenguaje natural. Los primeros experimentos del corpus emplearon GPT-4, GPT-3.5 y Alpaca para interpretar registros de robots y planes PDDL. Los resultados mostraron su potencial, pero también sus límites: una explicación más extensa no era necesariamente más correcta y los modelos más pequeños podían inventar eventos [20]. Posteriormente, la generación aumentada por recuperación (RAG) permitió seleccionar registros de episodios de ROS 2 y utilizarlos como contexto para responder preguntas conversacionales [21], [24]. No obstante, la calidad de la respuesta sigue dependiendo de la evidencia disponible. Si el registro no recoge una causa perceptiva, como el tipo de obstáculo detectado, el modelo no puede recuperarla. Los experimentos con modelos de visión y lenguaje (VLM) intentaron abordar esta carencia incorporando imágenes [22], [23].

En el periodo 2024–2026, estas corrientes avanzan hacia su integración y estandarización. El enfoque de *accountability* como servicio separa la captura, la transmisión continua y el almacenamiento de datos mediante microservicios, incorpora cifrado de extremo a extremo y evalúa la sobrecarga del sistema [6]. Por su parte, BCubed propone un esquema para cajas negras independiente de la capa intermedia, mientras que ACOLYTE permite extraer datos de plataformas ROS 2 y OBD-II [7]–[9]. La integración de Rosbag cifrado, RAG, LLM y VLM presentada en 2026 ilustra el valor de combinar evidencias textuales y visuales, aunque todavía constituye una prueba de concepto [23]. Persiste, por tanto, una distancia entre la integración técnica y la consolidación del campo: la revisión sistemática de 2025 señala que la generación de explicaciones en robótica sigue siendo un ámbito pequeño, sin una definición ni una metodología de evaluación compartidas [16].

Periodo	Corriente dominante	Contribución característica	Problema que permanece
2016–2018	*Accountability* y explicación como requisitos	Formalización, caja negra ética y verbalización	Definir qué evidencia basta y para quién
2019–2021	Mecanismos verificables y explicación estructurada	Registro resistente a manipulaciones, árboles de comportamiento, reconciliación de modelos e IEEE 7001	Integrar percepción, decisión y experiencia humana
2022–2024	Robots autónomos explicables y arquitecturas desacopladas	Revisiones, microservicios, RAG y primeros VLM	Fidelidad, latencia, privacidad y evaluación comparable
2025–octubre de 2026	Integración multimodal y estandarización	Revisión sistemática, BCubed y ACOLYTE, normas ISO y prueba de concepto con LLM y VLM	Escalabilidad, fundamentación causal y validación en campo

Tabla 2. Evolución de las corrientes que confluyen en EXPLICIT.

3.2 Ejes o líneas de investigación

3.2.1 *Accountability* y asignación de responsabilidad

La literatura entiende la *accountability* como una capacidad que depende del conjunto del sistema y de su contexto de uso. Para rendir cuentas sobre una conducta es necesario relacionar el sistema que la produce, las políticas que establecen qué se espera de él, las evidencias que permiten reconstruir lo ocurrido y una instancia capaz de evaluar las razones y atribuir responsabilidades. El modelo formal de Kacianka y Pretschner muestra que la interpretación de *accountability* determina qué actores, eventos y relaciones deben registrarse [2]. Por tanto, una caja negra genérica puede proporcionar una base común, pero cada despliegue necesita concretar cómo se relacionan sus peligros, funciones y decisiones con las evidencias necesarias para evaluarlos.

Esta concepción permite distinguir la *accountability* de dos elementos que contribuyen a ella, pero que por sí solos resultan insuficientes: el registro y la explicación. Conservar datos no garantiza que estos sean completos, fiables o interpretables, ni que permitan identificar el origen de un comando. Del mismo modo, explicar una acción puede facilitar su comprensión sin asegurar la cadena de custodia de las evidencias, la identificación de los actores o el cumplimiento de una política. Para atender estas necesidades, las arquitecturas más sólidas separan la conservación de evidencias, el razonamiento y la presentación de explicaciones. A la vez, mantienen identificadores que permiten rastrear cada afirmación hasta el evento que la respalda [5], [6].

La importancia de esta trazabilidad se hace especialmente visible en robótica, donde un resultado puede depender de la interacción entre personas, programas, modelos, componentes físicos y condiciones del entorno. Por ejemplo, un fallo de navegación puede tener su origen en una percepción degradada, una configuración inadecuada, un mapa obsoleto, una decisión del planificador, la saturación de recursos, la pérdida de un mensaje o una intervención maliciosa. Reconstruir lo ocurrido exige, por tanto, evidencias que permitan distinguir entre un error funcional, una limitación conocida, un uso indebido y un ciberataque. Los análisis de ciberseguridad del corpus refuerzan esta necesidad: observar únicamente el comportamiento aparente puede llevar a confundir las consecuencias de un incidente con sus causas [30], [31], [48].

Esta necesidad de conectar decisiones, evidencias y responsabilidades explica la relevancia de abordar la *accountability* durante todo el ciclo de vida. Las normas recientes desarrollan esta perspectiva desde ámbitos complementarios. ISO/IEC 42001 sitúa las responsabilidades y los controles dentro de un sistema de gestión [37]; ISO/IEC 23894 los vincula con la gestión de riesgos [38]; ISO/IEC 42005 exige documentar los impactos previsibles y las partes interesadas [39]; e ISO/IEC 12792 organiza los elementos de transparencia que pueden necesitar usuarios, integradores, auditores y autoridades [41]. En conjunto, estas normas exigen coherencia entre lo que se prevé durante el diseño, lo que ocurre durante la operación y lo que se comprueba mediante la monitorización y la evaluación.

3.2.2 Registro de eventos y registradores de caja negra

La caja negra ética propone un módulo pasivo que recibe información en una sola dirección y la registra con marcas temporales para facilitar la investigación de incidentes [3], [4]. La inspiración aeronáutica aporta dos principios: la independencia del registrador y la captura sistemática de datos. Sin embargo, trasladarlos a la robótica plantea una dificultad: las plataformas no comparten una interfaz universal equivalente a la de una aeronave certificada. Los sensores, los temas de ROS, los árboles de

comportamiento, los planificadores y los componentes aprendidos varían entre robots. Por ello, la estandarización debe establecer una base común y permitir extensiones adaptadas a cada plataforma.

Los esquemas propuestos intentan responder a esta diversidad. El borrador de estándar abierto distingue entre metadatos, datos de sensores y datos del robot [4]. BCubed desarrolla esta organización mediante tres tipos de registro —metadatos, datos del sistema y datos de resumen— e incorpora un campo flexible para información específica de cada plataforma [7]. El registro de resumen permite describir un episodio y sus componentes sin examinar todos los eventos. Sin embargo, organizar los datos no resuelve qué información debe conservarse. Registrar todo aumenta la duplicación, los costes y los problemas de privacidad; limitarse a eventos de alto nivel puede eliminar los detalles necesarios para identificar una causa.

Esta tensión resulta especialmente visible en los sistemas basados en ROS. ROS 2 facilita la observación del sistema al exponer temas, servicios, acciones y registros [29], pero estas interfaces no siempre permiten conocer las razones de una acción. Un tema de velocidad, por ejemplo, muestra el comando publicado, aunque puede no indicar qué objetivo, percepción o norma lo motivó. Para reconstruir ese contexto, los trabajos del corpus sobre explicaciones de navegación combinan posición, mapa, odometría, datos láser, estado de Nav2, árboles de comportamiento y Rosbag [21]–[23]. La selección de datos debe partir, por tanto, de las preguntas que una futura investigación necesitará responder.

Una vez seleccionada la información, es necesario decidir cómo y durante cuánto tiempo conservarla. Las imágenes aportan contexto perceptivo, pero también pueden concentrar la mayor parte del volumen almacenado. En la prueba de concepto multimodal del corpus, el tema de cámara alcanza aproximadamente 1,75 GB, una cantidad muy superior a la de las fuentes textuales [23]. Una política de retención viable debe combinar, según las necesidades del despliegue, ventanas temporales, captura activada por eventos, muestreo, compresión, eliminación de duplicados y almacenamiento fuera de la cadena de bloques.

Además de reducir el volumen, la conservación debe garantizar que los datos sigan siendo interpretables. Para ello, es necesario registrar las versiones de los programas y los modelos, la configuración y la información del reloj utilizada para ordenar los eventos. Sin este contexto, una actualización puede cambiar el significado atribuido a un mismo registro y dificultar la reconstrucción de lo ocurrido.

3.2.3 Integridad resistente a manipulaciones y cadena de bloques

La fiabilidad de una explicación depende de la integridad de las evidencias que la sustentan. Los sistemas de registro resistentes a manipulaciones abordan una amenaza que la explicabilidad clásica suele dejar en segundo plano: si un atacante o un componente defectuoso altera los datos, la explicación puede construirse sobre información falsa. Para afrontar este problema, White y colaboradores encadenan eventos mediante resúmenes criptográficos y emplean firmas, HMAC y contratos inteligentes para verificar su integridad y procedencia [5]. Su evaluación muestra que es posible ajustar la frecuencia de los puntos de control para limitar el tráfico. En una configuración representativa, el sistema requiere alrededor de 110 Kbps de ancho de banda y genera un crecimiento del registro distribuido inferior a 1 KB/s. Estos resultados respaldan la viabilidad de utilizar la cadena de bloques para verificar los registros sin almacenar en ella todo su contenido.

BCubed explora otra estrategia: almacenar registros estandarizados mediante contratos inteligentes, utilizando ACOLYTE para extraer los datos [7], [8]. En un caso de inspección robótica con ROS 2, esta

implementación produce un aumento contenido del uso de CPU y memoria, aunque introduce una latencia media de almacenamiento próxima a 0,1 segundos por registro [8]. El estudio comparativo de redes Ethereum del corpus también muestra las limitaciones de rendimiento. Anvil obtiene los mejores tiempos para desarrollo, mientras que Geth en modo de desarrollo ofrece un entorno más cercano a un cliente real y facilita la creación de redes privadas. Sin embargo, incluso el mejor tiempo de procesamiento para uno de los conjuntos de datos de ROS 2, de 26,556 segundos, supera la duración media del episodio sin interrupciones, de 19,5 segundos [9]. La escalabilidad y la eliminación de duplicados se convierten así en condiciones necesarias para sostener el registro durante la operación.

Además del rendimiento, es necesario distinguir entre preservar un dato y garantizar su veracidad. La cadena de bloques permite ordenar los registros, protegerlos frente a modificaciones posteriores y verificarlos de forma distribuida, pero no asegura que la información capturada sea correcta. Si un sensor está comprometido, una marca temporal es inconsistente o la identidad del emisor no está autenticada, el sistema puede conservar íntegramente un registro defectuoso. La protección debe comenzar, por tanto, en la adquisición de los datos e incluir gestión de claves, sincronización de relojes, mecanismos de atestación y control de acceso. También debe distinguir la evidencia primaria de los metadatos utilizados para verificarla. La elección de una red pública o privada y de sus permisos de participación debe responder al modelo de amenazas y a las necesidades de confidencialidad del despliegue.

La conservación de registros plantea, además, una tensión con la protección de datos. Almacenar información personal directamente en una cadena inmutable dificulta su rectificación y la aplicación de criterios de minimización. Una arquitectura más consistente mantiene los datos cifrados fuera de la cadena y utiliza esta para conservar resúmenes criptográficos, información de procedencia y referencias a las políticas aplicables. La divulgación selectiva permite, a su vez, limitar qué información recibe cada parte.

Los desarrollos del corpus avanzan en esta dirección al plantear cadenas privadas, almacenamiento descentralizado y reducción de duplicados [8], [9]. Estas decisiones permiten combinar la resistencia a manipulaciones con un almacenamiento viable y una divulgación controlada de las evidencias.

3.2.4 Generación de explicaciones estructuradas

Los métodos estructurados explican el comportamiento de un robot a partir de representaciones explícitas de sus decisiones. En planificación, la reconciliación de modelos identifica qué hechos o supuestos necesita conocer el usuario para comprender el plan del agente [17]. En los árboles de comportamiento, la organización en objetivos, subobjetivos, pasos y acciones permite explicar lo ocurrido con distintos niveles de detalle y localizar el punto de fallo [18]. Por su parte, las arquitecturas normativas explican las acciones mediante sus causas, propósitos y reglas, más allá de las correlaciones observadas [19].

Estos enfoques comparten una fortaleza: la explicación está vinculada a las estructuras que intervienen en la decisión o mantienen una relación definida con ella. Esto permite comprobar su fidelidad contrastándola con el plan, el árbol o la norma correspondiente. También facilita responder a preguntas como «por qué ocurrió», «por qué no se eligió otra opción», «cómo se ejecutó» o «qué falló». Cuando la representación es jerárquica, la explicación puede adaptarse al diálogo: ofrecer primero una respuesta breve y ampliar los detalles a medida que el usuario los solicita.

Sin embargo, esa vinculación también delimita lo que puede explicarse. Un árbol de comportamiento puede señalar que falló el control de proximidad, pero no identificar que había un brazo humano en una imagen si esa información nunca se incorporó a su representación. Del mismo modo, la reconciliación de

modelos requiere que los modelos del robot y del usuario puedan compararse, mientras que las ontologías necesitan mantenimiento para seguir representando el sistema. Las arquitecturas causales, además, exigen mecanismos explícitos para registrar las relaciones relevantes, lo que puede resultar costoso en sistemas que combinan módulos aprendidos y reglas.

Por tanto, la utilidad de estos métodos depende tanto de la calidad de sus representaciones como de la información que estas abarcan. La tendencia apunta a combinarlos con sistemas generativos: las estructuras aportan una base verificable y los modelos generativos permiten expresar su contenido de forma más flexible y adaptada al usuario.

3.2.5 Grandes modelos de lenguaje, recuperación aumentada y explicaciones multimodales

Los grandes modelos de lenguaje (LLM) facilitan la consulta de registros técnicos mediante preguntas en lenguaje natural. Sin embargo, la calidad de sus respuestas depende de la información disponible y de la pregunta planteada. En el estudio de 2023 sobre interpretación de comportamientos, GPT-4 obtuvo resultados generalmente mejores que GPT-3.5 y Alpaca, aunque incluso sus respuestas más extensas podían ser incorrectas [20]. Su principal aportación consiste, por tanto, en conectar información y expresarla de forma comprensible; la fluidez de una respuesta no garantiza su veracidad.

La generación aumentada por recuperación (RAG) busca fundamentar las respuestas seleccionando fragmentos de los registros del episodio antes de generar la explicación [24]. En la evaluación de navegación del corpus, el procesamiento de los registros tardó entre 20 y 30 segundos en la mayoría de las ejecuciones, con un caso cercano a 96 segundos. Una vez procesados, las respuestas se generaron normalmente en 5–7 segundos [21]. Los resultados fueron más sólidos en preguntas sobre el estado del robot y el resultado de sus acciones. En cambio, la pregunta sobre por qué había evitado un obstáculo falló en todas las ejecuciones: los registros recuperados no contenían la información perceptiva necesaria. Esta limitación revela un problema de observabilidad. Mejorar las instrucciones al modelo no basta cuando el sistema no ha registrado la información que permitiría responder.

Los modelos de visión y lenguaje (VLM) intentan cubrir esta carencia incorporando imágenes. El estudio preliminar de 2024 mostró que una imagen permitía identificar un obstáculo ausente del registro textual [22]. Posteriormente, la publicación de 2026 combinó Rosbag cifrado, recuperación de texto y descripciones visuales para explicar una maniobra de navegación ante un brazo humano [23]. En la configuración evaluada, obtuvo una recuperación ROUGE-1 de 0,655 y un valor BLEU de 0,323. Estas métricas muestran una coincidencia parcial con la explicación de referencia, pero no demuestran que la respuesta identifique correctamente las causas de la maniobra. Además, la evaluación emplea un modelo como evaluador semántico y se limita a un único escenario simulado, por lo que queda por comprobar si los resultados se mantienen en otros contextos.

La incorporación de imágenes tampoco elimina el riesgo de generar explicaciones sin respaldo suficiente. DriveBench evaluó doce VLM en diecisiete condiciones, con 19.200 imágenes y 20.498 pares de pregunta y respuesta. Sus resultados muestran que los modelos pueden producir respuestas plausibles apoyándose en conocimientos previos o en el texto, incluso cuando la evidencia visual está degradada o ausente [25]. Para EXPLICIT, esto implica que cada explicación multimodal debe indicar qué evidencias la respaldan, el estado de sus fuentes y el nivel de confianza, además de permitir que el sistema se abstenga de responder

cuando la información sea insuficiente. En sistemas críticos para la seguridad, la plausibilidad de una explicación debe acompañarse de un respaldo verificable.

Junto con la integración de evidencias, los modelos fundacionales permiten adaptar las explicaciones a cada destinatario. La investigación emergente en robots sociales propone ajustar las respuestas al conocimiento, los objetivos y el estado del usuario [26]. Esta personalización exige mantener estable el contenido de los hechos. Para ello, conviene separar una base de evidencias —con los eventos, las relaciones causales y las incertidumbres— de la capa que decide cómo comunicarla. Así pueden modificarse el vocabulario, la extensión y la modalidad de presentación para un operador, un desarrollador, un auditor o una persona afectada, manteniendo una misma reconstrucción de lo ocurrido.

3.2.6 Regulación, estándares y ciberseguridad

La normativa europea refuerza la necesidad de que los sistemas robóticos puedan documentar su funcionamiento y aportar evidencias sobre sus decisiones. El Reglamento de Inteligencia Artificial establece, para determinados sistemas de alto riesgo, requisitos de registro automático de eventos, documentación técnica, transparencia, supervisión humana, exactitud, robustez y ciberseguridad [32]. El calendario vigente sitúa la aplicación de las obligaciones para los sistemas del Anexo III en el 2 de diciembre de 2027 y para los sistemas de alto riesgo incorporados en productos regulados en el 2 de agosto de 2028 [33]. Aunque la clasificación de cada robot depende de su finalidad prevista y de la legislación sectorial aplicable, estos requisitos conectan directamente con el desarrollo de cajas negras y explicaciones respaldadas por evidencias.

El Reglamento de Máquinas concreta esta orientación en aspectos especialmente relevantes para la robótica. Cuando corresponda, las interfaces de maquinaria con comportamiento autónomo deben comunicar de forma comprensible qué acciones se han planificado y por qué se realizarán. También establece requisitos de protección frente a intentos maliciosos previsibles y de conservación de trazas de intervenciones y versiones de los programas de seguridad [34]. A ello se suma el Reglamento de Ciberresiliencia, cuya aplicación general comienza el 11 de diciembre de 2027, aunque las obligaciones de notificar vulnerabilidades explotadas e incidentes graves son aplicables desde el 11 de septiembre de 2026 [35]. Por su parte, la Directiva sobre Responsabilidad por Productos Defectuosos incluye los programas informáticos y los sistemas de IA en el concepto de producto y contempla defectos relacionados con las actualizaciones y la ciberseguridad [36].

Estas normas definen resultados que deben poder demostrarse, como la trazabilidad, el control de riesgos, la robustez y la comunicación adecuada. La elección de las herramientas para alcanzarlos debe justificarse en cada caso. Una cadena de bloques puede proteger los registros frente a manipulaciones, pero también puede hacerlo un registro de solo anexado con claves protegidas mediante componentes físicos. Del mismo modo, un LLM puede facilitar la comunicación en lenguaje natural, mientras que una plantilla estructurada puede ser más adecuada para explicar un evento crítico. La arquitectura debe partir de los riesgos, las necesidades de cada parte interesada y los resultados experimentales.

Esta elección también debe considerar que los mecanismos de *accountability* introducen sus propios riesgos de ciberseguridad. Los registros ayudan a investigar ataques, pero el componente que los captura y almacena puede filtrar información sensible, consumir recursos excesivos, sufrir una denegación de servicio o aceptar eventos falsificados. Las revisiones de ciberseguridad robótica identifican vulnerabilidades en las comunicaciones, la autenticación, la cadena de suministro de *software* y la

configuración [30], [31]. Por ello, el sistema de *accountability* necesita su propio análisis de amenazas, medidas de protección, gestión de actualizaciones y auditoría.

La explicabilidad comparte esta doble condición. Puede contribuir a la seguridad al revelar discrepancias entre lo que el robot pretende hacer, lo que percibe y cómo actúa, pero también puede exponer información sensible o facilitar la manipulación del sistema [45]. Su diseño debe establecer qué evidencias puede consultar cada parte interesada y conservar un registro de las consultas sensibles. Así, la capacidad de explicar y auditar el comportamiento se integra con la protección del propio sistema.

3.3 Consensos y hallazgos principales

El primer consenso es que *accountability* y *explainability* son complementarias. Una explicación fiable necesita evidencia; una evidencia preservada necesita interpretación para ser útil. Los trabajos integrados del corpus expresan esta relación de manera explícita [7], [8], [23]. El desacuerdo se concentra en cuánto registrar, qué nivel de la decisión conservar y qué mecanismo de integridad resulta proporcionado.

El segundo consenso es la dependencia de la parte interesada y del contexto. Las explicaciones deben variar en vocabulario, granularidad, momento y modalidad, pero conservar un núcleo común de hechos [10], [11], [15], [40], [41]. La personalización no justifica ocultar limitaciones ni alterar la causalidad. Un operador puede necesitar una instrucción inmediata; un desarrollador, una traza; un auditor, procedencia y versiones; una persona afectada, una razón comprensible y un canal de impugnación.

El tercero es que la integridad y la autenticidad son necesarias, pero insuficientes. Los resúmenes criptográficos y la cadena de bloques pueden mostrar que un registro no cambió; no demuestran que el sensor, la marca temporal o la identidad fueran correctos al capturarlo [5], [8]. El perímetro de confianza debe empezar antes del almacenamiento. La evidencia requiere autenticación del origen, relojes sincronizados, configuración segura, control de versiones y controles para lagunas o eventos perdidos.

El cuarto es la falta de evaluación compartida. La revisión sistemática de 2025 encuentra que aproximadamente la mitad de los trabajos no evalúa sus explicaciones y que los métodos, dominios y métricas impiden comparaciones directas [16]. Los resultados de LLM y VLM muestran capacidad lingüística, pero también errores por contexto ausente y falta de fundamentación visual [20]–[25]. Ninguna métrica aislada captura fidelidad, utilidad, latencia, privacidad y confianza calibrada.

El quinto es la inmadurez de la validación. La navegación y la robótica social, con frecuencia en simulación o laboratorios controlados, dominan la evidencia [16], [21]–[23]. Faltan estudios longitudinales, robots físicos en entornos abiertos, flotas, fallos compuestos, actualizaciones de modelos y condiciones adversariales. También faltan análisis del coste organizativo: quién configura el registro, quién revisa las explicaciones y cómo se preserva la evidencia durante el ciclo de vida.

El sexto consenso emergente es que la generación de explicaciones debe poder abstenerse. Los modelos fundacionales producen lenguaje convincente con evidencia insuficiente. DriveBench muestra que un VLM puede contestar a partir de conocimientos previos aunque la imagen no lo sustente [25]. En un sistema sujeto a rendición de cuentas, la respuesta correcta puede ser «los registros no permiten determinar la causa», acompañada de los datos disponibles y de la razón de la insuficiencia.

4 Justificación de la propuesta EXPLICIT

La aportación de EXPLICIT puede situarse en la conexión entre la captura de evidencias y la generación de explicaciones verificables. La literatura muestra una separación entre tres ámbitos: los sistemas de registro protegen la integridad de los datos, pero no garantizan que sean comprensibles; los sistemas explicativos producen respuestas en lenguaje natural, pero no siempre permiten comprobar de dónde procede cada afirmación; y los marcos regulatorios exigen evidencias y transparencia, aunque dejan abierta su implementación. EXPLICIT puede abordar esta desconexión mediante una arquitectura que permita seguir el recorrido desde el dato capturado hasta la explicación presentada al usuario [46], [47]. Esta propuesta se concreta en seis contribuciones complementarias.

La primera es un modelo de evidencias definido a partir de las preguntas que el sistema debe responder. Antes de seleccionar sensores o *topics* de ROS, es necesario identificar qué necesitan saber el operador, el desarrollador, el investigador, el auditor y la persona afectada. Cada pregunta permitirá determinar qué eventos, relaciones, versiones y garantías de procedencia deben conservarse. El modelo distinguirá entre observaciones, eventos inferidos, decisiones, acciones, resultados y restricciones de política. Así, cada explicación podrá señalar qué afirmaciones proceden directamente de los registros y cuáles son inferencias.

La segunda contribución es un registrador modular para ROS 2 que asegure la adquisición y conservación de esas evidencias. Deberá identificar el origen de los datos, mantener una secuencia ordenada de eventos y utilizar relojes sincronizados. También incorporará firmas o autenticación de mensajes, contenido cifrado, metadatos de versión y mecanismos que hagan explícitas las lagunas del registro. La cadena de bloques podrá conservar resúmenes criptográficos, versiones del esquema y eventos de custodia, mientras los datos de alta frecuencia permanecerán fuera de ella. Para justificar esta elección, se comparará al menos una configuración de cadena de bloques con permisos con una alternativa de solo anexado, evaluando las garantías que aporta cada mecanismo.

Sobre esta base, la tercera contribución será un motor de explicaciones con recuperación temporal y multimodal. Su función consistirá en seleccionar las evidencias relevantes para cada episodio: registros, estados del árbol de comportamiento o del planificador, imágenes y políticas aplicables. Esta selección acotará el contexto que recibe el modelo y evitará la necesidad de procesar un Rosbag completo en cada consulta. Las respuestas incluirán referencias a las evidencias y un nivel de confianza, y el sistema se abstendrá de responder cuando el respaldo sea insuficiente. Antes de presentar la explicación, una capa de validación mediante reglas comprobará las marcas temporales, las entidades y las relaciones utilizadas.

La cuarta contribución permitirá adaptar las explicaciones a distintos destinatarios manteniendo su consistencia. Para ello, se separará el plan de evidencias de su expresión en lenguaje natural. El primero recogerá las afirmaciones verificadas, los vínculos causales y las incertidumbres; la segunda ajustará el vocabulario, la extensión y el formato sin modificar los hechos. Una misma maniobra podrá dar lugar a una alerta breve para el operador, una explicación conversacional para el usuario o un informe técnico para auditoría. De este modo, será posible evaluar qué presentación facilita más la comprensión sin alterar la reconstrucción de lo ocurrido.

La quinta contribución será un protocolo que evalúe tanto el registro como las explicaciones y su utilidad para las personas. Las pruebas incluirán fallos y ciberataques controlados, además de ejecuciones correctas. El registrador se evaluará por su completitud, ordenación, integridad, sobrecarga, necesidades de almacenamiento y capacidad de recuperación. Para el motor explicativo se medirán la exactitud causal, la cobertura de las evidencias, la frecuencia de afirmaciones sin respaldo, la abstención, la latencia y la robustez ante evidencias corruptas. Los estudios con usuarios examinarán el desempeño en la tarea, la comprensión del funcionamiento del robot, la detección de errores y el ajuste de la confianza a la fiabilidad real del sistema, además de la satisfacción.

La sexta contribución organizará estos resultados en un mapa de evidencias para apoyar la evaluación de conformidad. Cada artefacto —como el esquema de datos, la política de conservación, la gestión de claves, los informes de pruebas y las trazas de explicación— se vinculará con las necesidades de registro, transparencia, supervisión humana, ciberseguridad, evaluación de impacto y trazabilidad de versiones. Este mapa proporcionará una estructura reutilizable para justificar las decisiones de diseño y presentar sus evidencias ante una auditoría, sin atribuir al sistema una conformidad automática [32]–[42].

Referencias

[1] S. Wachter, B. Mittelstadt y L. Floridi, "*Transparent, explainable, and accountable AI for robotics*", *Science Robotics*, vol. 2, núm. 6, eaan6080, 2017. https://doi.org/10.1126/scirobotics.aan6080

[2] S. Kacianka y A. Pretschner, "*Understanding and Formalizing Accountability for Cyber-Physical Systems*", en *2018 IEEE International Conference on Systems, Man, and Cybernetics*, pp. 3165–3170, 2018. https://doi.org/10.1109/SMC.2018.00536

[3] A. F. T. Winfield y M. Jirotka, "*The Case for an Ethical Black Box*", en *Towards Autonomous Robotic Systems*, LNCS 10454, pp. 262–273, 2017. https://doi.org/10.1007/978-3-319-64107-2_21

[4] A. F. T. Winfield, A. van Maris, P. Salvini y M. Jirotka, "*An Ethical Black Box for Social Robots: a Draft Open Standard*", 2022. https://arxiv.org/abs/2205.06564

[5] R. White, G. Caiazza, A. Cortesi, Y. I. Cho y H. I. Christensen, "*Black Block Recorder: Immutable Black Box Logging for Robots via Blockchain*", *IEEE Robotics and Automation Letters*, vol. 4, núm. 4, pp. 3812–3819, 2019. https://doi.org/10.1109/LRA.2019.2928780

[6] L. Fernández-Becerra, Á. M. Guerrero-Higueras, F. J. Rodríguez-Lera y V. Matellán, "*Accountability as a service for robotics: Performance assessment of different accountability strategies for autonomous robots*", *Logic Journal of the IGPL*, vol. 32, núm. 2, pp. 243–262, 2024. https://doi.org/10.1093/jigpal/jzae038

[7] L. Inyesto-Alonso, D. Sobrín-Hidalgo, C. Álvarez-Aparicio, V. Matellán-Olivera, A. Campazas-Vega y Á. M. Guerrero-Higueras, "*Defining a Standard Blockchain-based Black Box for Autonomous Systems*", en *Proceedings of the XXIV Workshop of Physical Agents*, pp. 46–59, 2024. https://hdl.handle.net/10045/146426

[8] L. Inyesto-Alonso et al., "*Traceability for Autonomous Systems: A Standardized Blockchain-Based Black Box*", *IEEE Transactions on Industrial Informatics*, vol. 22, núm. 9, pp. 8445–8456, 2026. https://doi.org/10.1109/TII.2026.3692951

[9] L. Inyesto-Alonso, C. Álvarez-Aparicio, C. Abad-Moya, A. Campazas-Vega, V. Matellán-Olivera y Á. M. Guerrero-Higueras, "*A comparative analysis of Ethereum development networks for the purpose of accountability in autonomous systems*", manuscrito incluido en el corpus del proyecto, 2026.

[10] IEEE, IEEE 7001-2021 *Standard for Transparency of Autonomous Systems*, 2021. https://standards.ieee.org/ieee/7001/6929/

[11] T. Miller, "*Explanation in artificial intelligence: Insights from the social sciences*", *Artificial Intelligence*, vol. 267, pp. 1–38, 2019. https://doi.org/10.1016/j.artint.2018.07.007

[12] D. Gunning y D. Aha, "*DARPA's Explainable Artificial Intelligence Program*", *AI Magazine*, vol. 40, núm. 2, pp. 44–58, 2019. https://doi.org/10.1609/aimag.v40i2.2850

[13] S. Anjomshoae, A. Najjar, D. Calvaresi y K. Främling, "*Explainable Agents and Robots: Results from a Systematic Literature Review*", en *Proceedings of the 18th International Conference on Autonomous Agents and MultiAgent Systems*, pp. 1078–1088, 2019. https://dl.acm.org/doi/10.5555/3306127.3331806

[14] S. Wallkötter, S. Tulli, G. Castellano, A. Paiva y M. Chetouani, "*Explainable Embodied Agents Through Social Cues: A Review*", *ACM Transactions on Human-Robot Interaction*, vol. 10, núm. 3, art. 27, 2021. https://doi.org/10.1145/3457188

[15] T. Sakai y T. Nagai, "*Explainable autonomous robots: a survey and perspective*", *Advanced Robotics*, vol. 36, núms. 5–6, pp. 219–238, 2022. https://doi.org/10.1080/01691864.2022.2029720

[16] D. Sobrín-Hidalgo, Á. M. Guerrero-Higueras y V. Matellán-Olivera, "*Generating Explanations for Autonomous Robots: A Systematic Review*", *IEEE Access*, vol. 13, pp. 20413–20426, 2025. https://doi.org/10.1109/ACCESS.2025.3535097

[17] T. Chakraborti, S. Sreedharan, Y. Zhang y S. Kambhampati, "*Plan Explanations as Model Reconciliation: Moving Beyond Explanation as Soliloquy*", en *Proceedings of IJCAI 2017*, pp. 156–163, 2017. https://doi.org/10.24963/ijcai.2017/23

[18] Z. Han, D. Giger, J. Allspaw, M. S. Lee, H. Admoni y H. A. Yanco, "*Building the Foundation of Robot Explanation Generation Using Behavior Trees*", *ACM Transactions on Human-Robot Interaction*, vol. 10, núm. 3, art. 26, 2021. https://doi.org/10.1145/3457185

[19] T. Arnold, D. Kasenberg y M. Scheutz, "*Explaining in Time: Meeting Interactive Standards of Explanation for Robotic Systems*", *ACM Transactions on Human-Robot Interaction*, vol. 10, núm. 3, art. 25, 2021. https://doi.org/10.1145/3457183

[20] M. Á. González-Santamarta et al., "*Using Large Language Models for Interpreting Autonomous Robots Behaviors*", en *Hybrid Artificial Intelligent Systems*, LNCS, pp. 533–544, 2023. https://doi.org/10.1007/978-3-031-40725-3_45

[21] D. Sobrín-Hidalgo et al., "*Explaining Autonomy: Enhancing Human-Robot Interaction through Explanation Generation with Large Language Models*", arXiv:2402.04206, 2024. https://doi.org/10.48550/arXiv.2402.04206

[22] D. Sobrín-Hidalgo et al., "*Enhancing Robot Explanation Capabilities through Vision-Language Models: A Preliminary Study by Interpreting Visual Inputs for Improved Human-Robot Interaction*", arXiv:2404.09705, 2024. https://doi.org/10.48550/arXiv.2404.09705

[23] L. Fernández-Becerra, D. Sobrín-Hidalgo, M. A. González-Santamarta, Á. M. Guerrero-Higueras, F. J. Rodríguez-Lera y V. Matellán-Olivera, "*Improving accountability and explainability in robots through encryption, large language models, and visual language models*", *Logic Journal of the IGPL*, vol. 34, núm. 1, jzaf016, 2026. https://doi.org/10.1093/jigpal/jzaf016

[24] P. Lewis et al., "*Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*", *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020. https://papers.nips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html

[25] S. Xie et al., "*Are VLMs Ready for Autonomous Driving? An Empirical Study from the Reliability, Data and Metric Perspectives*", en *Proceedings of ICCV 2025*, pp. 6585–6597, 2025. https://doi.org/10.1109/ICCV51701.2025.00621

[26] E. Doğan, A. Markelius y H. Gunes, "*Designing Social Robots with Ethical, User-Adaptive Explainability in the Era of Foundation Models*", en *Companion of the ACM/IEEE International Conference on Human-Robot Interaction*, 2026. https://doi.org/10.1145/3776734.3794453

[27] L. Longo et al., "*Explainable Artificial Intelligence (XAI) 2.0: A manifesto of open challenges and interdisciplinary research directions*", *Information Fusion*, vol. 106, 102301, 2024. https://doi.org/10.1016/j.inffus.2024.102301

[28] S. Yadollahi, A. M. Zanchettin, A. Ajoudani y K. Darvish, "*Explainability for Human-Robot Collaboration*", en *Companion of the 2024 ACM/IEEE International Conference on Human-Robot Interaction*, 2024. https://doi.org/10.1145/3610978.3638154

[29] S. Macenski, T. Foote, B. Gerkey, C. Lalancette y W. Woodall, "*Robot Operating System 2: Design, architecture, and uses in the wild*", *Science Robotics*, vol. 7, núm. 66, eabm6074, 2022. https://doi.org/10.1126/scirobotics.abm6074

[30] J.-P. A. Yaacoub, H. N. Noura, O. Salman y A. Chehab, "*Robotics cyber security: vulnerabilities, attacks, countermeasures, and recommendations*", *International Journal of Information Security*, vol. 21, pp. 115–158, 2022. https://doi.org/10.1007/s10207-021-00545-8

[31] N. Verma, N. Kumar, C. Verma, Z. Illés y D. Singh, "*A systematic review on cybersecurity of robotic systems: vulnerabilities trends, threats, attacks, challenges, and proposed framework*", *International Journal of Information Security*, vol. 24, art. 127, 2025. https://doi.org/10.1007/s10207-025-01041-z

[32] Unión Europea, Reglamento (UE) 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial, 2024. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

[33] Comisión Europea, "*AI Act: regulatory framework and application timeline*", versión consultada el 23 de octubre de 2026. https://digital-strategy.ec.europa.eu/en/policies/regulatory-framework-ai

[34] Unión Europea, Reglamento (UE) 2023/1230 relativo a las máquinas, versión consolidada de 27 de julio de 2026. https://eur-lex.europa.eu/eli/reg/2023/1230/2026-07-27/eng

[35] Unión Europea, Reglamento (UE) 2024/2847 relativo a los requisitos horizontales de ciberseguridad para los productos con elementos digitales, 2024. https://eur-lex.europa.eu/eli/reg/2024/2847/oj

[36] Unión Europea, Directiva (UE) 2024/2853 sobre responsabilidad por los daños causados por productos defectuosos, 2024. https://eur-lex.europa.eu/eli/dir/2024/2853/oj

[37] ISO/IEC, ISO/IEC 42001:2023 *Information technology — Artificial intelligence — Management system*, 2023. https://www.iso.org/standard/42001

[38] ISO/IEC, ISO/IEC 23894:2023 *Information technology — Artificial intelligence — Guidance on risk management*, 2023. https://www.iso.org/standard/77304.html

[39] ISO/IEC, ISO/IEC 42005:2025 *Information technology — Artificial intelligence — AI system impact assessment*, 2025. https://www.iso.org/standard/42005

[40] ISO/IEC, ISO/IEC TS 6254:2025 *Information technology — Artificial intelligence — Objectives and approaches for explainability and interpretability of machine learning models and artificial intelligence systems*, 2025. https://www.iso.org/standard/82148.html

[41] ISO/IEC, ISO/IEC 12792:2025 *Information technology — Artificial intelligence — Transparency taxonomy of AI systems*, 2025. https://www.iso.org/standard/84111.html

[42] ISO/IEC, ISO/IEC TR 5469:2024 *Artificial intelligence — Functional safety and AI systems*, 2024. https://www.iso.org/standard/81283.html

[43] S. Rosenthal, S. P. Selvaraj y M. Veloso, "*Verbalization: Narration of Autonomous Robot Experience*", en *Proceedings of IJCAI 2016*, pp. 862–868, 2016. https://www.ijcai.org/Proceedings/16/Papers/127.pdf

[44] E. Moscatelli et al., "*Assessing Transparency of Robots, Exoskeletons, and Assistive Devices: A Systematic Review*", *Sensors*, vol. 25, núm. 14, 4444, 2025. https://doi.org/10.3390/s25144444

[45] M. S. Roque y S. K. Damodaran, "*Explainable AI for the security of human-interactive robots*", *International Journal of Human-Computer Interaction*, vol. 38, núm. 18–20, pp. 1789–1807, 2022. https://doi.org/10.1080/10447318.2022.2066246

[46] Universidad de León, "EXPLICIT: Memoria científico-técnica individual", documento de proyecto incluido en el corpus, 2024.

[47] Universidad de León, "Reporte técnico TESCAC 2025", documento de proyecto incluido en el corpus, 2025.

[48] Universidad de León, "CEN Entregable A4 E4.3 Investigación: metodología de auditoría de ciberseguridad y casos robóticos", documento de proyecto incluido en el corpus, versión 0.2, 2026.